



Tecnológico de Monterrey

Reto 1 - Documento de correcciones

Estudiantes:

Luis Fernando Cruz Flores | A01738347
Yestli Darinka Santos Sánchez | A01736992
Luis Angel Zempoalteca Serrano | A01738862

Nombre de la Institución:

Instituto Tecnológico y de Estudios Superiores de
Tecnológico de Monterrey

Materia:

Inteligencia artificial avanzada para la ciencia de datos

Clave:

TC3009C.601

Grupo:

601

Fecha:

8 de Septiembre de 2026

Durante el desarrollo de la solución del reto y las diferentes iteraciones del documento y de los notebooks, surgieron algunos errores y áreas de oportunidad, las cuales ayudaron a obtener una solución más robusta y completa del reto, a continuación algunas de las correcciones que realizamos al documento y a los notebooks;

(i) Análisis Exploratorio (EDA)

Tratamiento de Valores Faltantes Semánticos:

Uno de los cambios más significativos respecto a las iteraciones anteriores radica en la interpretación y manejo de los datos nulos. Durante las primeras fases del análisis exploratorio, se identificó que diversas variables predictoras presentaban un índice de valores faltantes superior al 80%. Inicialmente, esto podría haberse interpretado como una deficiencia en la calidad del conjunto de datos o como ruido que no aportaría utilidad a los modelos predictivos.

Sin embargo, al profundizar en la naturaleza de los atributos, se determinó que estos vacíos correspondían a "valores faltantes semánticos". Es decir, el dato nulo no representaba un error de captura ni una pérdida de información, sino que codificaba la ausencia física de una característica arquitectónica específica en la vivienda evaluada. Dos ejemplos claros de este fenómeno son la variable PoolQC, donde el vacío indicaba que la propiedad no contaba con piscina, y la variable Alley, que señalaba la falta de acceso a un callejón.

Actualización metodológica en la iteración actual:

A partir de este hallazgo analítico, la estrategia dentro del flujo del notebook fue rediseñada. Se aplicó una técnica de imputación, reemplazando los nulos con una etiqueta categórica (como "None")

(ii) Preparación de los datos

Transformación Logarítmica de algunos valores:

Durante la fase de exploración, se evidenció que tanto la variable objetivo (SalePrice) como diversas variables continuas relacionadas con las dimensiones geométricas de las propiedades (tales como LotArea, GrLivArea, TotalBsmtSF y MasVnrArea) presentaban un sesgo positivo muy pronunciado y rangos de valores extremadamente altos.

Para preparar adecuadamente los datos antes del entrenamiento, se integró la aplicación de la función $\log(1 + x)$ (logaritmo natural) sobre este grupo específico de variables. Esta decisión metodológica cumple propósitos técnicos críticos para el éxito de los modelos de regresión:

- Mitigación del apalancamiento (leverage): Comprime la escala de los valores extremos (por ejemplo, residencias excepcionalmente grandes o de costos anómalos), reduciendo el peso desproporcionado que estos puntos podrían tener al sesgar la pendiente de ajuste del modelo.

- Estabilización de la varianza y el error: Al trabajar en una escala logarítmica, el modelo penaliza de forma equitativa los errores proporcionales o relativos, evitando que las magnitudes absolutas masivas dominen la función de pérdida y distorsionen las predicciones de propiedades estándar.

Tratamiento experimental del periodo 2008–2010:

Debido a que el conjunto de datos registra transacciones inmobiliarias efectuadas entre 2006 y 2010, abarca de manera intrínseca el colapso del mercado derivado de la crisis de 2008.

Inicialmente, se planteó la hipótesis de que incluir estas observaciones atípicas podría distorsionar la métrica de error del modelo, lo que sugería la eliminación de los registros correspondientes a 2008–2010.

Para abordar este escenario sin descartar información de forma arbitraria, se diseñó un experimento estructurado de evaluación. Mediante validación cruzada (5-fold Cross-Validation), se comparó el rendimiento de un modelo entrenado con la totalidad de los años frente a uno entrenado exclusivamente con los datos previos a la crisis ($YrSold < 2008$), evaluando ambos sobre los mismos subconjuntos de validación. Esta decisión metodológica cumple propósitos críticos para el rigor analítico del proyecto:

- Toma de decisiones basada en evidencia empírica: Permite cuantificar matemáticamente el verdadero impacto de las fluctuaciones macroeconómicas, comprobando si el algoritmo es capaz de asimilar el contexto atípico de la crisis o si, por el contrario, el ruido introducido degrada sus predicciones.
- Prevención de pérdida de información (Data Loss): Evita la reducción drástica e injustificada de la muestra de entrenamiento. Al someter a prueba la retención frente a la exclusión de los datos, se garantiza que cualquier modificación al volumen del dataset esté respaldada empíricamente por el error predictivo (cuyos resultados definitivos se presentan en la fase de Evaluación).