



CRISP-DM

Reto 1 - Predicción de precios de vivienda

Estudiantes:

Luis Fernando Cruz Flores | A01738347
Yestli Darinka Santos Sánchez | A01736992
Luis Angel Zempoalteca Serrano | A01738862

Nombre de la Institución:

Instituto Tecnológico y de Estudios Superiores de Monterrey

Materia:

Inteligencia artificial avanzada para la ciencia de datos

Clave:

TC3009C.601

Grupo:

601

Fecha:

18 de Septiembre de 2026

1. Entendimiento del negocio

1.1. Determinar los objetivos de negocio

Antecedentes

Actualmente, la estimación del valor de las propiedades residenciales (específicamente en Ames, Iowa) es un proceso altamente complejo. Tradicionalmente, los compradores, vendedores y agentes inmobiliarios basan sus estimaciones en unas pocas variables superficiales, como el número de habitaciones, los metros cuadrados o la apariencia general. Sin embargo, la realidad del mercado demuestra que el valor final de venta (SalePrice) está influenciado por una cantidad mucho mayor de características detalladas y ocultas (como la calidad de los materiales, la zonificación, el estado de las instalaciones, etc.). Analizar manualmente esta gran cantidad de variables para determinar un precio justo resulta ineficiente y propenso a errores humanos.

Objetivos del negocio

Predecir con precisión el precio de venta SalePrice de una vivienda residencial a partir de sus características físicas, de calidad y de ubicación, de manera que sirva como apoyo objetivo para la toma de decisiones de compra, venta y tasación de inmuebles, reduciendo la dependencia de estimaciones manuales basadas únicamente en comparables.

Criterios de éxito empresarial

- El modelo predice el precio de venta con un margen de error suficientemente bajo como para ser útil en decisiones reales de compra, venta o tasación de una vivienda.
- Se identifica con claridad qué características de la vivienda (tamaño, calidad, ubicación, antigüedad, etc.) tienen mayor influencia en su precio, aportando información útil para justificar valuaciones.
- La estimación de precio es consistente entre viviendas similares, evitando sobrevaloraciones o subvaloraciones frente al comportamiento real del mercado.

1.2. Evaluar la situación

Además de estimar el precio de venta, el proyecto busca responder preguntas de negocio relacionadas: ¿qué características de una vivienda tienen mayor peso en su valor (tamaño, calidad de acabados, ubicación, antigüedad)? ¿Cómo varía el precio entre distintas zonas (Neighborhood)? ¿Qué tanto afectan las remodelaciones o el año de construcción al precio final?

Entre los riesgos identificados y sus medidas de mitigación se encuentran:

- *Riesgo*: variables con muchos valores faltantes que en realidad indican ausencia de una característica y no un error (por ejemplo, PoolQC, Alley, Fence). *Mitigación*: imputar estos casos como una categoría explícita ("Sin característica") según lo indicado en el diccionario de datos, en lugar de eliminarlos.

- *Riesgo*: variables categóricas con muchas categorías distintas, como Neighborhood. *Mitigación*: Las variables categóricas se procesaron mediante OneHotEncoder(handle_unknown="ignore") dentro del pipeline
- *Riesgo*: valores atípicos en variables de área (como GrLivArea o LotArea) que podrían distorsionar el modelo. *Mitigación*: identificarlos mediante análisis gráfico (diagramas de dispersión contra SalePrice) y decidir si se eliminan o se tratan antes del modelado.
- *Riesgo*: sobreajuste del modelo, dado el alto número de variables (79) frente al tamaño de la muestra (1,460 registros). *Mitigación*: usar validación cruzada y técnicas de regularización al construir los modelos.

1.3. Determinar los objetivos de la minería de datos

Criterios de éxito de la minería de datos:

- Se trabaja sobre el logaritmo de SalePrice porque es la métrica oficial que usa Kaggle para calificar esta competencia, y porque el precio de venta tiene una distribución sesgada a la derecha (pocas casas muy caras que distorsionarían el error si se midiera en dólares), al usar el logaritmo, un error del mismo porcentaje pesa igual tanto en una casa barata como en una costosa, evitando que el modelo se enfoque solo en acertar las viviendas más caras.
- Superar el desempeño de un modelo base simple (por ejemplo, Regresión Lineal utilizando el mismo conjunto de predictores y el mismo pipeline de preprocesamiento.).
- Obtener un modelo capaz de generar predicciones en el formato requerido por sample_submission.csv.
- RMSLE: La evaluación del desempeño se realiza calculando la raíz del error cuadrático medio entre el logaritmo del valor predicho y el logaritmo del valor real observatorio. Justificación:

Sensibilidad a errores relativos (porcentuales): Al tomar el logaritmo de las variables, la métrica penaliza de igual forma los errores proporcionales. Un error de \$10,000 USD en una casa de \$50,000 USD no representa lo mismo que en una de \$500,000 USD. El RMSLE asegura que ambas desviaciones tengan el peso adecuado según la magnitud de la propiedad.

Mitigación de asimetría: La variable *SalePrice* presenta un sesgo positivo pronunciado hacia la derecha. La transformación logarítmica estabiliza la varianza de los residuos y evita que las residencias de muy alto valor distorsionen y dominen la función de pérdida del modelo.

1.4. Elaborar un plan de proyecto

Planeación:

Semana 1: Etapa 1. Comprensión del negocio

- Definir objetivos empresariales, evaluar la situación y establecer criterios de éxito (Completado).
- Determinar los objetivos de minería de datos enfocados en el Log RMSE.
- Elaborar el plan de proyecto detallado y diseñar el diagrama de Gantt.

Semanas 2 y 3: Etapa 2. Adquisición y comprensión de datos

- Descargar y cargar los archivos de entrenamiento y prueba de Kaggle.
- Realizar el Análisis Exploratorio de Datos (EDA) para analizar las 79 variables predictoras y su relación con "SalePrice".
- Detectar problemas de calidad y valores faltantes
- Limpiar, transformar y preparar los datos (codificación de categorías) para dejarlos listos para los algoritmos.

Semanas 4 y 5: Etapa 3. Modelado y Evaluación

- Seleccionar las técnicas de regresión supervisada.
- Diseñar el esquema de prueba dividiendo los datos de entrenamiento para validación cruzada.
- Construir y entrenar los modelos predictivos iniciales.
- Evaluar el rendimiento de los modelos y optimizar parámetros (reevaluar los parámetros).

Semana 6: Etapa 4. Despliegue

- Ejecutar el modelo final sobre los datos sin etiquetar.
- Construir y exportar el archivo sample_submission.csv en el formato requerido.
- Redactar el reporte de resultados, evaluar el proceso general y documentar los próximos pasos.




Fig. 1. Diagrama de Gantt del proyecto

Herramientas:

- *Recursos Humanos:* 3 Científicos de Datos voluntarios
- *Software:* Python, Jupyter Notebook, Google Colab
- *Librerías:* scikit-learn, NumPy, pandas, Matplotlib, seaborn
- *Hardware de desarrollo:*

Laptop Dell G15 5511, Procesador: Intel Core i7-11800H (11.^a generación) @ 2.30 GHz, 16 hilos, Tarjeta gráfica: NVIDIA GeForce RTX 3050 Laptop GPU (4 GB VRAM dedicada), Memoria RAM: 16 GB (8 GB de fábrica + 8 GB adicionales instalados), Almacenamiento: SSD original + disco interno adicional de 1 TB, Sistema operativo: Windows 11 Home

ROG FlowZ13, Processor (CPU): 12th Gen Intel Core™ i9-12900H (14 cores: 6 P-cores, 8 E-cores) , Graphics (GPU): NVIDIA GeForce RTX 4050 (4 GB VRAM), Memory (RAM): 16GB LPDDR5, Windows 11

MacBook Pro (14 pulgadas, Nov 2023), Procesador: Apple M3 (CPU de 8 núcleos), Tarjeta gráfica: GPU integrada de 10 núcleos, Memoria RAM: 16 GB unificada, Almacenamiento: SSD Macintosh HD, Pantalla: 14.2" Liquid Retina XDR (ProMotion 120 Hz), Sistema operativo: macOS Sequoia 15.7.3

2. Entendimiento de los datos

2.1. Recopilación de datos iniciales

- Proveedor/Plataforma: Kaggle.
- Autor: Dean De Cock (quien preparó la descripción original de las propiedades).
- Archivos disponibles y contenido: train.csv, test.csv, data_description.txt, sample_submission.csv
- Acceso y descarga: en la pestaña "Data" de la competencia House Prices - Advanced Regression Techniques en Kaggle.
- Alcance de los datos y restricciones de uso
- Alcance geográfico: Ciudad de Ames, Iowa, EE. UU.
- Alcance temporal: Las ventas registradas abarcan principalmente el periodo entre 2006 y 2010.
- Incentivo: Se trata de una competencia de tipo Knowledge / Getting Started, por lo que no cuenta con premio monetario. Su propósito principal es el aprendizaje práctico, el desarrollo de habilidades en ingeniería de características y el uso de algoritmos avanzados.
- Evaluación del submission: El modelo final debe generar predicciones para las 1,459 observaciones no etiquetadas (test.csv) e ingresarse a la plataforma de Kaggle para calificar el desempeño sobre el Leaderboard público y privado utilizando el archivo sample_submission.csv

2.2. Describir los datos

El conjunto de entrenamiento contiene 1,460 observaciones y 81 columnas: 79 variables potencialmente predictoras, el identificador Id y la variable objetivo SalePrice. El conjunto de prueba contiene 1,459 observaciones y 80 columnas: las mismas 79 variables predictoras y Id, pero sin SalePrice.

Nombre de la Variable	Significado / Descripción	Tipo	Unidad / Rango / Categorías
SalePrice	Precio de venta de la propiedad	Numérica Continua	Dólares (\$), rango aprox. 34,900 - 755,000
MSSubClass	Tipo de propiedad involucrada en la venta	Categórica Nominal (Codificada)	Códigos numéricos: 20 (1-Story), 60 (2-Story 1946+), 70 (2-Story 1945-), etc.

LotArea	Tamaño del lote o terreno	Numérica Continua	Pies cuadrados (\$ft^2\$)
OverallQual	Calidad del material y acabado general	Categórica Ordinal	Escala entera del 1 (Very Poor) al 10 (Very Excellent)
YearBuilt	Fecha original de construcción	Numérica Discreta (Año)	Años (ej. 1872 - 2010)
GrLivArea	Área habitable sobre el nivel del suelo	Numérica Continua	Pies cuadrados (\$ft^2\$)
Neighborhood	Ubicación física dentro de los límites de la ciudad	Categórica Nominal	Nombres de zonas/colonias (ej. <i>NAmes</i> , <i>CollgCr</i> , <i>OldTown</i>)

Variable Objetivo: SalePrice es numérica continua, requiere un modelo de regresión.

Variables que requieren tratamiento especial

- Identificador único: Id debe eliminarse del entrenamiento para evitar sobreajuste.
- Fechas / Años (YearBuilt, YearRemodAdd, YrSold, GarageYrBlt): No se deben tratar como números independientes; conviene transformarlas en variables de antigüedad o antigüedad al momento de la venta
- Variables Categóricas con NaNs funcionales: En variables como Alley, BsmtQual, FireplaceQu, GarageType y Fence, los valores nulos (NA) no representan datos faltantes, sino la ausencia de la característica (ej. "Sin Garaje" o "Sin Chimenea"). Requieren imputación explícita con una etiqueta tipo 'SinCaracterística'.
- Las variables categóricas almacenadas como texto, tanto nominales como ordinales, fueron tratadas mediante OneHotEncoder dentro del pipeline de modelado. Esta decisión evita imponer distancias numéricas artificiales entre categorías y permite aplicar exactamente la misma transformación durante entrenamiento, validación y predicción.

2.3. Explorar los datos

Variables Numéricas:

- SalePrice : Promedio de \$180,921 USD (mediana de \$163,000 USD), oscilando entre un mínimo de \$34,900 USD y un máximo de \$755,000 USD.
- Superficie Habitable (GrLivArea): Promedio de 1,515.46 sqft (rango entre 334 y 5,642 sqft).
- Área Total del Sótano (TotalBsmtSF): Promedio de 1,057.43 sqft.
- Año de Construcción (YearBuilt): Mediana de construcción en 1973 (construcción más antigua registrada en 1872 y la más reciente en 2010).

Variables Categóricas:

- Zonificación (MSZoning): Dominada fuertemente por zonas residenciales de baja densidad (RL con 1,151 observaciones de 1,460).
- Vecindarios (Neighborhood): Existen 25 vecindarios distintos, siendo el más frecuente NAmes (North Ames) con 225 viviendas.
- Tipo de Propiedad (BldgType): Principalmente viviendas unifamiliares aisladas (1Fam representa 1,220 de los casos).




Fig. 2. Gráfica de distribución

Relaciones entre Variables

Relación con la Variable Objetivo :

- Calidad General (OverallQual): Muestra la correlación más alta positiva. A mayor calidad percibida, el precio promedio se incrementa sustancialmente.

- Superficie (GrLivArea, TotalBsmtSF, 1stFlrSF): Exhiben una fuerte asociación positiva lineal con el precio de venta.
- Garaje (GarageCars, GarageArea): Un mayor número de espacios para automóviles correlaciona positivamente con el valor comercial.

Relaciones Inter-VARIABLES (Multicolinealidad):

- Existe una correlación intrínseca alta entre la superficie del primer piso (1stFlrSF) y el total del sótano (TotalBsmtSF), así como entre los coches del garaje (GarageCars) y su área total (GarageArea).

Precaución Causal: Una correlación alta entre OverallQual y SalePrice no significa mecánicamente que cambiar una variable aumente el precio en esa magnitud exacta; existen variables omitidas (ubicación, acabados, estado del mercado) que inciden simultáneamente en ambas.

Valores Atípicos, Sesgos, Desbalance de Clases y Patrones

Sesgo Positivo (Asimetría en SalePrice):

- La distribución del precio está sesgada hacia la derecha (la media de \$180,921 sobrepasa a la mediana de \$163,000).
- *Impacto:* Los modelos de regresión lineal simple sufrirán violaciones del supuesto de normalidad en residuos. Se recomienda aplicar una transformación logarítmica ($\log(1 + \text{SalePrice})$).

Valores Atípicos (Outliers):

- En la relación GrLivArea vs SalePrice, existen viviendas con áreas excepcionalmente grandes (> 4,000 sqft) pero con precios inusualmente bajos (< \$200,000 USD).
- *Impacto:* Estos puntos ejercen un alto apalancamiento (*high leverage*) en algoritmos de regresión, distorsionando la pendiente de ajuste. Conviene eliminarlos antes del modelado.

Desbalance Extremo en Categorías (Predominio):

- Variables como Utilities (1,459 de 1,460 son "AllPub") o Street (1,454 son "Pave") Aunque presentan muy poca variabilidad, en el flujo final no se eliminaron manualmente. Se conservaron para mantener la información disponible y permitir que los propios modelos, especialmente los regularizados como Lasso, reduzcan el peso de características poco útiles.

Tendencias y Temporalidad (YrSold, MoSold):

- Las ventas muestran estacionalidad anual marcada en los meses de mayo, junio y julio (MoSold 5, 6 y 7). Sin embargo, a nivel de año (YrSold 2006-2010), el volumen de transacciones se mantuvo plano debido al choque de la crisis inmobiliaria global de 2008.

Estos resultados indican que las viviendas con mejor calidad, mayor superficie, más baños, sótanos más grandes y mayor capacidad de garaje tienden a alcanzar precios más elevados.

Estrategias para Variables Distribuidas Asimétricamente y Datos de Crisis

- Transformación Logarítmica: Además de aplicar la transformación logarítmica a la variable objetivo ($\log(1 + \text{SalePrice})$), se identificaron variables continuas de superficie (como LotArea, GrLivArea, TotalBsmtSF y MasVnrArea) con rangos de valores extremadamente altos. Se aplicará la función $\log(1 + x)$ sobre estas variables para reducir el apalancamiento (leverage) de los valores extremos en los modelos de regresión.
- Tratamiento experimental del periodo 2008–2010: debido a que el conjunto de datos incluye ventas anteriores y posteriores al inicio de la crisis inmobiliaria, se planteó como hipótesis que eliminar las observaciones de 2008–2010 podría modificar el rendimiento predictivo. En lugar de asumir que dichos años distorsionan los datos, esta decisión se evaluó experimentalmente mediante validación cruzada, comparando el entrenamiento con todos los años frente al entrenamiento excluyendo 2008–2010. Los resultados de este experimento se presentan en la fase de Evaluación.

2.4. Verificar la calidad de los datos

Valores codificados como ausencia de característica

Al revisar el diccionario de datos, se identificó que varias columnas presentan NA no porque el dato se haya perdido, sino porque codifican explícitamente que la vivienda no cuenta con esa característica. Antes de calcular los faltantes reales, estos valores se reclasificaron: se imputó la etiqueta "*SinCaracteristica*" en las variables categóricas (PoolQC, MiscFeature, Alley, Fence, FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond, BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2) y el valor 0 en sus variables numéricas asociadas (GarageYrBlt, GarageArea, GarageCars, BsmtFinSF1, etc.), correspondientes a:

- PoolQC (~99.5%, 1,453 filas): sin alberca.
- MiscFeature (~96.3%, 1,406 filas): sin características adicionales.
- Alley (~93.8%, 1,369 filas): sin acceso a callejón.
- Fence (~80.8%, 1,179 filas): sin cerca.
- FireplaceQu (~47.3%, 690 filas): sin chimenea.
- Variables de garaje (~5.5%, 81 filas): sin garaje.
- Variables de sótano (~2.5%, 37-38 filas): sin sótano.

Valores realmente faltantes

- LotFrontage (frente del terreno): 259 valores faltantes (~17.7%). Requiere imputación (por ejemplo, con la mediana por Neighborhood).

Duplicados

Se verificó con `df.duplicated()` tanto sobre todas las columnas como excluyendo Id; no se encontró ningún registro duplicado.

Outliers

Mediante boxplots y el método de rango intercuartílico (IQR) sobre GrLivArea, se detectaron 2 viviendas con área habitable mayor a 4,000 pies² pero con precio de venta anormalmente bajo outliers documentados explícitamente por el autor del dataset (De Cock) como recomendables de eliminar.

Errores de tipo/captura

Se encontró un valor imposible en GarageYrBlt (año 2207, posterior al año de venta), corregido asumiendo que coincide con el año de construcción de la vivienda (YearBuilt).

En síntesis, los problemas de calidad detectados en esta etapa son: columnas con más del 80% de "faltantes" que en realidad indican ausencia codificada de la característica (PoolQC, MiscFeature, Alley); 2 outliers documentados en GrLivArea vs. SalePrice; un valor erróneo en GarageYrBlt (2207); y multicolinealidad alta entre GarageCars/GarageArea, GrLivArea/TotRmsAbvGrd, YearBuilt/GarageYrBlt y TotalBsmtSF/1stFlrSF.

Consistencia entre Variables y Representatividad

Consistencia Interna:

- Superficies: Se cumple la regla lógica: $\text{GrLivArea} = \text{1stFlrSF} + \text{2ndFlrSF} + \text{LowQualFinSF}$.
- Fechas: Generalmente, $\text{YearRemodAdd} \geq \text{YearBuilt}$. En casos donde no hubo remodelación, la fecha de remodelación coincide con el año de construcción.

Representatividad respecto al Problema:

- Geográfica: Representa únicamente la ciudad de Ames, Iowa entre los años 2006 y 2010. Los hallazgos y modelos no son directamente extrapolables a mercados nacionales o metrópolis grandes.
- Condiciones Macroeconómicas: Cubre el periodo de la crisis inmobiliaria de 2008-2009, lo que introduce un sesgo temporal en los valores monetarios.

Data Leakage y Disponibilidad en Tiempo Real

Variables de Venta (SaleType, SaleCondition):

- SaleType (ej. si fue venta al contado, por ejecución hipotecaria o venta normal) y SaleCondition (ej. venta rápida, entre familiares, o transacción normal) se determinan durante o después de la negociación final.
- Riesgo: Si se intenta predecir el valor de mercado de una casa antes de sacarla a la venta, estas variables no estarían disponibles o influirían artificialmente si se asume un tipo de venta especial.

MoSold y YrSold:

- Indican el momento exacto de cierre de la transacción. Para tasar una vivienda en la actualidad, se debe cuidar no utilizar información del "futuro" dentro de la validación cruzada.

En el conjunto de prueba (test.csv):

- La variable SalePrice está excluida correctamente, asegurando que no haya filtración directa del valor objetivo.

Resumen de Problemas a Resolver en la Fase de Preparación de Datos

Tratamiento de Valores Nulos:

- Reemplazar NaN por el valor categórico "SinCaracteristica" en variables donde la ausencia representa falta de la amenidad (PoolQC, MiscFeature, Alley, Fence, FireplaceQu, Garage*, Bsmt*).
- Reemplazar NaN por 0 en variables numéricas asociadas (GarageArea, GarageCars, BsmtFinSF1, etc.).
- Imputar LotFrontage utilizando la mediana agrupada por Neighborhood.

Corrección de Errores de Captura:

- Se detectó en test.csv un valor imposible de GarageYrBlt = 2207. Se sustituyó por el valor correspondiente de YearBuilt, evitando conservar un año de construcción del garaje posterior al periodo observado.

Transformación y Codificación de Variables:

- Convertir MSSubClass de número entero a tipo texto/categórico.

Transformación de la Variable Objetivo (SalePrice):

- Aplicar una transformación logarítmica ($\log(1 + y)$) a SalePrice para mitigar el sesgo positivo y estabilizar la varianza de los residuos.

Filtrado de Outliers

- Eliminar del conjunto de entrenamiento los registros con $GrLivArea > 4000$ sqft y $SalePrice < 200000$ para evitar distorsiones en los coeficientes del modelo.

3. Preparación de los datos

3.1. Seleccionar los datos

El conjunto de entrenamiento original contiene 1,460 viviendas. SalePrice se definió como variable objetivo y las 79 características restantes, excluyendo Id, constituyeron inicialmente el conjunto potencial de predictores.

Id se conservó durante la preparación únicamente para mantener la trazabilidad entre registros y para construir posteriormente el archivo submission.csv; sin embargo, se excluyó del conjunto de variables utilizadas para entrenar los modelos.

Se eliminaron dos predictores redundantes identificados durante el análisis exploratorio:

- GarageArea, debido a su fuerte relación con GarageCars.
- TotRmsAbvGrd, debido a su fuerte relación con GrLivArea.

Esta eliminación tuvo como objetivo reducir redundancia, particularmente para los modelos lineales, sin efectuar una selección agresiva de variables.

A diferencia de una iteración inicial del proyecto, no se conservaron únicamente las 30 variables con mayor correlación individual con SalePrice. El flujo definitivo mantiene los predictores disponibles después de las exclusiones justificadas y permite que los algoritmos regularizados determinen qué características resultan útiles durante el entrenamiento.

3.2. Limpiar los datos

La limpieza se realizó de manera reproducible tanto sobre train.csv como sobre test.csv, evitando utilizar información de SalePrice del conjunto de prueba.

En el conjunto de entrenamiento se eliminaron dos observaciones consideradas atípicas que cumplían simultáneamente:

$$GrLivArea > 4000 \text{ y } SalePrice < 200000$$

Por esta razón, el conjunto de entrenamiento pasó de 1,460 a 1,458 observaciones.

Los valores faltantes que representan ausencia real de una característica, como sótano, garaje, alberca, chimenea o cerca, fueron tratados de forma semántica. Las variables categóricas correspondientes se rellenaron con la categoría SinCaracteristica, mientras que las variables numéricas asociadas se rellenaron con 0.

Para LotFrontage, los valores faltantes se imputaron utilizando la mediana correspondiente a cada Neighborhood, calculada únicamente a partir del conjunto de entrenamiento. En los casos donde no fue posible obtener dicha mediana se utilizó la mediana global del entrenamiento.

Los faltantes restantes se trataron con la moda del entrenamiento para variables categóricas y con la mediana del entrenamiento para variables numéricas. Además, en test.csv se corrigió el valor imposible GarageYrBlt = 2207, sustituyéndolo por el YearBuilt de la misma vivienda. Al finalizar esta fase no quedaron valores nulos en los conjuntos preparados.

3.3. Construir los datos

Se crearon 5 variables nuevas a partir de las existentes:

Variable nueva	Qué representa
Edad_Casa	YrSold - YearBuilt
Area_Total_Construida	Suma de sótano + planta baja + planta alta
Total_Banos	Baños equivalentes (completos + 0.5 por medio baño)
Es_Remodelada	Indicador binario: 1 si YearRemodAdd es diferente de YearBuilt
Log_SalePrice	$\log(1 + \text{SalePrice})$ como objetivo en entrenamiento




Fig. 3. Matriz de correlación

3.4. Integrar los datos

No fue necesario realizar uniones entre múltiples bases de datos. train.csv y test.csv pertenecen a la misma competencia y comparten el mismo esquema de variables predictoras.

Ambos conjuntos se procesaron mediante las mismas reglas de limpieza y construcción de variables. Las estadísticas necesarias para imputar valores del conjunto de prueba (medianas y modas) fueron calculadas exclusivamente utilizando el conjunto de entrenamiento.

Como productos de esta fase se generaron:

- train_clean.csv: 1,458 filas y 84 columnas.
- test_clean.csv: 1,459 filas y 82 columnas.

3.5. Formatear los datos

- En la versión final se decidió separar la limpieza de las transformaciones que aprenden parámetros.
- MSSubClass y MoSold se trataron como variables categóricas, aunque originalmente se encontraban almacenadas mediante códigos numéricos.

- Se aplicó la transformación $\log_{1p}()$ a LotArea, GrLivArea, TotalBsmtSF y MasVnrArea. Esta operación es determinista para cada observación y no requiere aprender parámetros del resto del conjunto de datos.
- Después de eliminar SalePrice, Log_SalePrice e Id, el conjunto utilizado para modelar contiene 81 variables predictoras: 77 variables originales conservadas más las cuatro variables derivadas.
- La codificación y el escalamiento se implementaron dentro de un Pipeline de scikit-learn. Las variables numéricas se transformaron con StandardScaler y las categóricas con OneHotEncoder(handle_unknown="ignore").
- Estas transformaciones se ajustaron únicamente con los datos de entrenamiento de cada partición. De esta forma se evita que las medias, desviaciones o categorías presentes en los datos de prueba participen indirectamente en el entrenamiento, reduciendo el riesgo de data leakage.
- En la partición utilizada durante el experimento se identificaron 36 variables numéricas y 45 categóricas. Después del One-Hot Encoding, el pipeline generó 325 características numéricas para los algoritmos.

4. Modelado

4.1. Seleccionar la técnica de modelado

Debido a que SalePrice es una variable numérica continua, el problema se planteó como una tarea de regresión supervisada.

Se seleccionaron cinco algoritmos con diferentes niveles de complejidad para comparar su capacidad predictiva bajo las mismas condiciones de entrenamiento:

- Regresión Lineal se utilizó como modelo base o baseline. Permite establecer el rendimiento que puede alcanzarse mediante una relación lineal sin regularización.
- Ridge extiende la regresión lineal incorporando regularización L2, que penaliza coeficientes excesivamente grandes y puede reducir problemas asociados con multicolinealidad y sobreajuste.
- Lasso utiliza regularización L1. Además de controlar la magnitud de los coeficientes, puede reducir algunos de ellos hasta cero, por lo que realiza implícitamente una forma de selección de características.
- Random Forest Regressor combina múltiples árboles de decisión mediante bagging. Puede representar relaciones no lineales e interacciones entre variables, aunque presenta un costo computacional y una complejidad de interpretación superiores a los modelos lineales.

- Gradient Boosting Regressor construye árboles de forma secuencial, de manera que cada nuevo estimador intenta corregir parte de los errores producidos por los anteriores. Esto permite modelar relaciones no lineales complejas.

Los modelos se implementaron utilizando scikit-learn. Todos utilizaron como variable objetivo $\text{Log_SalePrice} = \log_{1p}(\text{SalePrice})$ y fueron evaluados mediante el mismo pipeline y la misma partición de datos.

4.2. Generar el diseño de la prueba

Después de la limpieza quedaron 1,458 observaciones etiquetadas. Estas se dividieron aleatoriamente en:

- 80% para entrenamiento: 1,166 observaciones.
- 20% para prueba final interna: 292 observaciones.

Se utilizó `random_state = 42` para garantizar la reproducibilidad de la partición.

El conjunto de prueba interno permaneció separado durante el ajuste de hiperparámetros. Dentro de las 1,166 observaciones de entrenamiento se utilizó validación cruzada K-Fold de cinco particiones, con mezcla aleatoria y la misma semilla.

La Regresión Lineal funcionó como baseline para determinar si los modelos regularizados y los modelos basados en árboles aportaban una mejora real.

La métrica principal fue el RMSE calculado sobre $\log_{1p}(\text{SalePrice})$, donde valores menores representan un mejor desempeño. Como métricas complementarias se calcularon MAE y R^2 , también sobre la variable objetivo transformada.

Para evitar fuga de información, `StandardScaler` y `OneHotEncoder` se incluyeron dentro de cada pipeline. De esta manera, cada transformación fue ajustada únicamente utilizando los datos disponibles en el entrenamiento correspondiente.

No se utilizó estratificación, ya que el problema es de regresión y la variable objetivo es continua. La posible influencia temporal de los años 2008–2010 se evaluó posteriormente mediante un experimento específico en lugar de modificar la partición principal.

4.3. Construir modelo

Los cinco modelos se entrenaron inicialmente bajo una configuración base y posteriormente se ajustaron los hiperparámetros utilizando exclusivamente el conjunto de entrenamiento.

Para Ridge y Lasso se utilizó `GridSearchCV`, evaluando explícitamente varios valores de α .

- Para Ridge se probaron: $\alpha \in \{1, 5, 10, 20, 50, 100\}$

obteniéndose: $\alpha = 20$

con un RMSE promedio de validación cruzada aproximado de 0.1110.

- Para Lasso se probaron: $\alpha \in \{0.0002, 0.0003, 0.0005, 0.0007, 0.001, 0.002\}$

obteniéndose: $\alpha = 0.0005$

con un RMSE promedio de validación cruzada de 0.1105.

- Para Random Forest y Gradient Boosting se utilizó RandomizedSearchCV. La configuración seleccionada para Random Forest fue: $n_estimators = 250$, $max_depth = 20$, $min_samples_leaf = 2$, $max_features = 0.5$.

Su RMSE promedio de validación cruzada fue aproximadamente 0.1323.

- Para Gradient Boosting se seleccionó: $n_estimators = 250$, $learning_rate = 0.10$, $max_depth = 2$, $subsample = 0.8$, $loss = "huber"$.

Su RMSE promedio de validación cruzada fue aproximadamente 0.1146.

- La Regresión Lineal se conservó sin ajuste de regularización para utilizarla como referencia.
- Los parámetros óptimos encontrados para el gradient boosting fueron: $subsample = 0.8$, $n_estimators = 200$, $max_depth = 2$, y $learning_rate = 0.05$

4.4. Evaluar el modelo

	RMSE_train	RMSE_test	MAE_test	R2_test	Brecha_train_test	Interpretabilidad
Lasso	0.0954	0.1108	0.0766	0.9271	0.0155	Alta
Gradient Boosting	0.0854	0.1126	0.0797	0.9247	0.0273	Media
Ridge	0.0941	0.1163	0.0781	0.9198	0.0222	Alta
Random Forest	0.0610	0.1379	0.0915	0.8873	0.0769	Media
Regresión Lineal	0.0839	0.1413	0.0902	0.8816	0.0574	Alta

MODELO SELECCIONADO: Lasso
RMSE_test: 0.1108
R2_test: 0.9271

Fig. 4. Evaluación de Modelos

El modelo Lasso obtuvo el menor RMSE sobre datos no vistos, con un valor de 0.1108, además del menor MAE y el R^2 más alto entre los modelos comparados.

Respecto al baseline de Regresión Lineal, cuyo RMSE fue de 0.1413, Lasso redujo el error en aproximadamente:

$$\frac{0.1413 - 0.1108}{0.1413} \times 100 \approx 21.5\%$$

La diferencia entre RMSE de entrenamiento y prueba para Lasso fue de únicamente 0.0155, lo que indica un balance favorable entre ajuste y capacidad de generalización.

Random Forest mostró una situación distinta: obtuvo un RMSE de entrenamiento muy bajo de 0.0610, pero aumentó hasta 0.1379 en prueba. La brecha de 0.0769 constituye una señal de sobreajuste.

Aunque Gradient Boosting obtuvo un error de entrenamiento menor que Lasso, su RMSE en prueba fue ligeramente superior. Por esta razón, y considerando además la menor complejidad y mayor interpretabilidad del modelo regularizado, Lasso fue seleccionado como modelo final.




Fig. 5. Comparativa de Modelos

5. Evaluación

5.1. Evaluar los resultados

El modelo Lasso seleccionado alcanzó un RMSE de 0.1108 y un R^2 de 0.9271 sobre el conjunto de prueba interno. Esto representa una mejora aproximada del 21.5% en RMSE respecto a la Regresión Lineal utilizada como baseline.

El resultado indica que las características disponibles permiten explicar una parte considerable de la variación observada en $\log_{1p}(\text{SalePrice})$. Sin embargo, el valor de R^2 debe interpretarse sobre la escala logarítmica utilizada durante el entrenamiento y no directamente como porcentaje de precisión en dólares.

La regularización L1 utilizada por Lasso permite reducir la contribución de características poco útiles, mientras conserva las variables que aportan información predictiva. Esto resulta especialmente apropiado después del One-Hot Encoding, que incrementa considerablemente el número de columnas disponibles.

También se evaluó la hipótesis planteada durante el entendimiento de los datos acerca de eliminar las ventas pertenecientes a los años 2008–2010. Utilizando cinco particiones de validación cruzada se obtuvieron:

Promedio CV:	
RMSE_todos_los_años	0.1105
RMSE_sin_2008_2010	0.1198

La eliminación del periodo 2008–2010 empeoró el RMSE en los cinco folds. En promedio, el error aumentó aproximadamente 8.4%. Por lo tanto, la hipótesis de que eliminar los años asociados a la crisis mejoraría el modelo no fue respaldada por la evidencia y se decidió conservar todo el periodo disponible.

Desde el punto de vista del negocio, el modelo puede utilizarse como evidencia de que las características físicas, de calidad, antigüedad y ubicación contienen suficiente información para producir estimaciones consistentes dentro del contexto del conjunto de Ames Housing.

No obstante, el modelo presenta limitaciones importantes. Los datos corresponden exclusivamente a Ames, Iowa, y al periodo 2006–2010, por lo que no existe evidencia suficiente para afirmar que mantendría el mismo desempeño en otras ciudades o en el mercado inmobiliario actual. Además, variables como SaleType, SaleCondition, MoSold y YrSold están disponibles para la tarea de Kaggle, pero algunas podrían no conocerse al realizar una tasación antes de una transacción real. Por este motivo, el resultado debe considerarse un modelo predictivo válido para el contexto del reto y no un sistema de tasación listo para uso comercial.

5.2. Revisar el proceso

La revisión del proceso permitió identificar y corregir una decisión importante realizada durante una iteración anterior.

Inicialmente, después del One-Hot Encoding, se habían generado aproximadamente 261 columnas y posteriormente se conservaron únicamente las 30 con mayor correlación absoluta individual con SalePrice. Aunque esta estrategia permitía obtener un conjunto más pequeño, presentaba dos problemas: una correlación individual baja no implica necesariamente que una variable sea inútil en combinación con otras, y realizar la selección utilizando SalePrice antes de separar entrenamiento y prueba podía introducir sesgo de selección.

Por ello, el flujo definitivo eliminó la selección arbitraria de 30 variables. Se conservaron las características disponibles después de las exclusiones justificadas de `GarageArea` y `TotRmsAbvGrd`, y la selección implícita se delegó a modelos regularizados como Lasso.

Asimismo, en la iteración anterior el escalamiento se realizaba antes de la separación de entrenamiento y prueba. El flujo final corrigió este punto incorporando `StandardScaler` y `OneHotEncoder` dentro de un Pipeline, de forma que sus parámetros se ajustan exclusivamente con los datos de entrenamiento.

La separación entre preparación y modelado también fue mejorada. `train_clean.csv` y `test_clean.csv` contienen únicamente los resultados de limpieza y construcción de variables, mientras que las transformaciones dependientes del entrenamiento permanecen dentro del pipeline.

El proceso completo es reproducible mediante `random_state = 42`, una partición 80/20 y validación cruzada de cinco folds.

Estas modificaciones explican también por qué el resultado final mejoró considerablemente respecto a la primera iteración del proyecto.

5.3. Determinar los próximos pasos

A partir de los resultados obtenidos se decidió avanzar a la fase de despliegue correspondiente al alcance académico del proyecto.

El modelo seleccionado es Lasso con $\alpha = 0.0005$. Para generar las predicciones finales se reentrena utilizando las 1,458 observaciones limpias disponibles, después de lo cual se aplica sobre las 1,459 observaciones no etiquetadas de `test.csv`.

Como trabajo posterior se considera conveniente evaluar modelos adicionales de boosting, como XGBoost, utilizando exactamente la misma partición y métricas para mantener una comparación justa. Este experimento se considera complementario y no modifica retrospectivamente la selección del modelo ni el `submission.csv` correspondiente al flujo principal.

Para una posible aplicación inmobiliaria real sería necesario realizar una nueva iteración de CRISP-DM con información más reciente, validación temporal y posiblemente un conjunto de variables que estuviera disponible antes de la venta.

6. Despliegue

6.1. Planificar el despliegue

El proyecto no contempla el despliegue de una aplicación, API o sistema en producción. Debido a que su contexto es académico y corresponde a una competencia de Kaggle, el despliegue se realiza como un proceso batch de generación de predicciones.

Después de seleccionar Lasso como modelo final, se volvió a entrenar el pipeline utilizando las 1,458 viviendas etiquetadas disponibles. A continuación, el modelo generó las predicciones para las 1,459 viviendas de test_clean.csv.

Debido a que el modelo predice $\log_{10}(\text{SalePrice})$, las predicciones fueron transformadas nuevamente a la escala monetaria mediante:

$$\text{SalePrice} = \exp(\text{predicción}_{\log}) - 1$$

Finalmente se generó submission.csv, compuesto exactamente por las columnas:

- Id
- SalePrice

Se verificó que el archivo contuviera 1,459 registros y que no existieran valores faltantes en las predicciones.

Los principales entregables del despliegue son el notebook de preparación, el notebook de modelado y evaluación, los conjuntos train_clean.csv y test_clean.csv, el archivo submission.csv y el presente informe.

6.2. Supervisión y mantenimiento del plan

Debido a que el resultado no se encuentra desplegado como servicio de producción, no existe un proceso de supervisión continua en tiempo real.

Sin embargo, se definieron controles para garantizar la reproducibilidad del proceso antes de cada nueva ejecución. Se debe verificar que la estructura de las columnas sea compatible con la utilizada durante el entrenamiento, que la limpieza no deje valores faltantes y que las transformaciones se realicen mediante el mismo pipeline.

El desempeño interno puede revisarse mediante RMSE en validación cruzada y en el conjunto de prueba. Como referencia mínima, una nueva versión del modelo debería continuar superando el RMSE de 0.1413 obtenido por la Regresión Lineal baseline; si deja de hacerlo, deberá revisarse el procesamiento, los datos o la configuración del modelo.

En caso de utilizar el modelo con nuevos periodos temporales, nuevas ciudades o distribuciones de propiedades diferentes, será necesario realizar nuevamente la fase de evaluación y posiblemente reentrenar el modelo. También deben versionarse los datos, el código y los hiperparámetros utilizados para cada ejecución

6.3. Informe final

Se integran las seis fases de CRISP-DM y documenta la evolución completa del proyecto: comprensión del problema, análisis y calidad de los datos, preparación, modelado, evaluación y despliegue.

Los principales resultados técnicos son la selección de Lasso con $\alpha = 0.0005$, un RMSE de prueba de 0.1108, un MAE de 0.0766 y un R^2 de 0.9271 sobre la escala logarítmica.

Asimismo, se documentó el experimento relacionado con el periodo 2008–2010, concluyendo que conservar dichos registros produjo un RMSE promedio de validación cruzada menor que eliminarlos.

Para permitir la reproducción y auditoría del proyecto, el informe se acompaña de los notebooks utilizados, los archivos preparados, la configuración del pipeline y el archivo final de predicciones para Kaggle.

Las principales limitaciones identificadas son el alcance geográfico exclusivo de Ames, Iowa, el periodo histórico 2006–2010 y la posible indisponibilidad de algunas variables de venta en una aplicación de tasación previa a una transacción.

6.4. Revisar el proyecto

El proyecto alcanzó el objetivo técnico de construir un modelo de regresión capaz de predecir SalePrice y superar el desempeño de una Regresión Lineal utilizada como baseline.

Uno de los principales aprendizajes fue que reducir el conjunto a las variables con mayor correlación individual no necesariamente produce el mejor modelo. La revisión de esta decisión condujo a conservar una mayor cantidad de información y utilizar regularización para controlar la complejidad.

También se comprobó la importancia de aplicar el preprocesamiento dentro de un pipeline. Ajustar el escalamiento y la codificación únicamente con datos de

entrenamiento permitió evitar que información del conjunto de prueba influyera indirectamente en el entrenamiento.

Otro resultado relevante fue comprobar experimentalmente la hipótesis relacionada con la crisis inmobiliaria. En lugar de eliminar las observaciones de 2008–2010 por una suposición previa, la comparación mediante validación cruzada demostró que conservarlas producía mejores resultados.

Finalmente, la comparación entre algoritmos mostró que un modelo más complejo no necesariamente produce un mejor resultado. Lasso superó ligeramente a Gradient Boosting y presentó una menor brecha entre entrenamiento y prueba, además de una mayor interpretabilidad.

En futuras iteraciones se recomienda evaluar modelos adicionales como XGBoost, incorporar información inmobiliaria más reciente y realizar validaciones temporales o externas antes de considerar una aplicación fuera del contexto de Kaggle.

Anexos:

Repositorio de Github: <https://github.com/LuisFerFlores31/House-Prices-Prediction>

Competencia de kaggle: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/>